

# **Extracting Policies from Replays to Improve MCTS in Real Time Strategy Games**

Zuozhi Yang, Santiago Ontanón

Drexel University, Philadelphia, Pennsylvania

# RTSy > gry planszowe

- Większy współczynnik rozgałęzienia drzewa (ang. *branching factor*)
  - Szachy:  $\sim 20$
  - Go:  $< 361$
  - Starcraft:  $30^{50} - 30^{200}$
- Rozgrywka w czasie rzeczywistym – ograniczony czas na obliczenia

# μRTS

- Minerały 
- Budynki:
  - Baza 
  - Baraki 
- Jednostki
  - Lekka 
  - Ciężka 
  - Zasięgowa 




Figure 1: A Screenshot of μRTS.

# Monte Carlo Tree Search


- Oceniamy sytuację wykonując symulowane rozgrywki.
- Budujemy drzewo gry (na początku składające się z jednego węzła – stanu przed ruchem komputera)
- Dla każdego rozwiniętego węzła utrzymujemy statystyki, mówiące o tym, kto częściej wygrywał gry rozpoczynające się w tym węźle
- Rozwijamy wybrany węzeł dodając jego dzieci i przeprowadzając rozgrywkę.

# Monte Carlo Tree Search


- Wybór (ang. *selection*): zaczynając od korzenia drzewa **R**, wybieraj kolejne węzły potomne, aż dotrzesz do liścia drzewa **L**. (*tree policy*)
- Rozrost (ang. *expansion*): o ile **L** nie kończy gry, utwórz w nim jeden lub więcej węzłów potomnych i wybierz z nich jeden węzeł **C**
- Symulacja (ang. *playout*): rozegraj losową symulację z węzła **C** (*playout policy*)
- Propagacja wstecz (ang. *backpropagation*): na podstawie wyniku rozegranej symulacji uaktualnij informacje w węzłach na ścieżce prowadzącej od **C** do **R**.

# Monte Carlo Tree Search


Wybór




Rozrost



Symulacja



Propagacja wstecz



# Tree Policy Learning

- *Supervised learning* na podstawie działań botów
- Wynik – model  $p_u(a_i | s)$ 
  - Wejście:  $s$  – wektor stanu gry „z punktu widzenia” jednostki  $u$
  - Wyjście:  $(a_1, a_2, \dots, a_n)$  – prawdopodobieństwa wszystkich  $n$  akcji, jakie jednostka może wykonać
- Model jest wykorzystywany z każdym użyciem *tree policy*
- 8 cech do reprezentowania stanu gry

# Naiwny klasyfikator bayesowski (ang. *Naive Bayes classifier*)

- Zakładamy, że wszystkie cechy są niezależne.

$$p(\mathbf{x}|y = c, \boldsymbol{\theta}) = \prod_{i=1}^D p(x_i|y = c, \boldsymbol{\theta}_{ic})$$

- Założenie o niezależności cech jest zwykle nieprawdziwe.
- Semi-Naive Bayes – prawdopodobieństwo dla danej cechy, zależy od n innych cech



# Drzewa decyzyjne

- **Budowanie drzewa**

- Podział węzła według cechy dającej największy zysk informacji (entropia)
- Rozkłady prawdopodobieństwa w liściach
- Pruning (a threshold confidence interval – 25%)
- Liście zdominowane przez jedną klasę – można zamienić prawdopodobieństwa na 0/1
- Laplace smoothing

# Drzewa decyzyjne - ulepszenia

- **Bootstrapped aggregating (bagging)**
- **Random forest**
  - $\log(n) + 1$  cech
  - 100 drzew